

Predicción de la Calificación de Examen Final mediante una Red Neuronal Implementada desde Cero

Emilio Torres Paul – A01753010

1. Resumen

Este documento resume la implementación de una red neuronal simple, construida desde cero (sin usar un *framework* de aprendizaje automático), para predecir la calificación de examen final de estudiantes a partir de su porcentaje de asistencia y sus horas de estudio semanales. Se describe la preparación de los datos, el análisis exploratorio (*EDA*) que sustentó la selección de variables, la arquitectura de la red, su entrenamiento mediante retropropagación (*backpropagation*), y los resultados obtenidos tanto en términos de error de regresión como de una clasificación complementaria aprobado/reprobado.

El análisis muestra que, si bien las variables elegidas tienen una correlación comparativamente alta con la calificación final, el modelo no puede superar cierto nivel de exactitud debido a que otras variables del conjunto de datos que no fueron utilizadas por la red, también están correlacionadas con el resultado.

2. Introducción

Predecir el desempeño académico a partir de indicadores de comportamiento, como la asistencia o el tiempo de estudio, es un ejercicio habitual para introducirse en el aprendizaje supervisado. En este proyecto, en lugar de utilizar un *framework* como *TensorFlow* o *PyTorch*, se implementó manualmente una red neuronal *feedforward* pequeña, con el objetivo de comprender a fondo cada paso del proceso: la propagación hacia adelante, el cálculo del error y la retropropagación que ajusta los pesos de la red.

El conjunto de datos utilizado corresponde a un registro de 1,000 estudiantes con información sobre su asistencia, horas de estudio, horas de sueño, antecedentes académicos y otros atributos. A partir de estas variables, se buscó predecir la calificación obtenida en el examen final (*final_exam_score*).

3. Metodología (preparación de los datos y EDA)

El conjunto de datos utilizado (*student_performance_dataset.csv*) fue obtenido de la plataforma *Kaggle*. Antes de construir la red, se realizó un análisis exploratorio de datos (*EDA*) que incluyó una revisión inicial de las variables disponibles y la construcción de un mapa de calor de correlaciones entre las variables numéricas y categóricas (codificadas mediante *one-hot encoding*) frente a *final_exam_score*.

Este análisis mostró que *study_time_hours* presentaba la correlación más alta con la calificación final (0.57), seguida de *previous_grade* (0.41). Por tratarse de las dos variables de comportamiento

estudiantil más fuertemente correlacionadas y las más interpretables y accionables, se seleccionaron como las únicas entradas de la red, manteniendo así una arquitectura pequeña y fácil de inspeccionar manualmente.

Los datos se dividieron en un conjunto de entrenamiento (70%, 700 observaciones) y uno de prueba (30%, 300 observaciones). Las variables de entrada se escalaron dividiendo cada columna entre su valor máximo dentro del conjunto de entrenamiento, y la calificación final se escaló dividiéndola entre 100, de modo que quedara dentro del rango (0,1) que la red puede producir en su salida. Los mismos factores de escalamiento del entrenamiento se reutilizaron para el conjunto de prueba, evitando así que información de este último influyera en el proceso de preparación de los datos.

4. Creación de la Red

Se construyó una red neuronal *feedforward* con una arquitectura 2-3-1: dos entradas (para *previous_grade* y *study_time_hours*), tres neuronas en una capa oculta y la variable de salida. Todas las neuronas utilizan una función de activación sigmoide, y los pesos de las dos matrices que conectan las capas ($W1$ y $W2$) se inicializaron con valores aleatorios provenientes de una distribución normal estándar; con el bias iniciando en 0.

El entrenamiento se realizó mediante descenso de gradiente, repitiendo 10,000 veces un ciclo de propagación hacia adelante y retropropagación sobre las 700 observaciones de entrenamiento, con una tasa de aprendizaje de 0.01. En cada iteración, el error entre la predicción y el valor real se combina con la derivada de la función sigmoide para calcular, mediante la regla de la cadena, cuánto debe ajustarse cada peso de la red.

5. Resultados de la Red

Sobre el conjunto de prueba, la red obtuvo un Error Cuadrático Medio (MSE) de aproximadamente 0.0065, en la escala normalizada de 0 a 1 en la que trabaja la salida de la red.

Adicionalmente, las predicciones se convirtieron en una clasificación binaria aprobado/reprobado, utilizando un umbral de aprobación de 70 puntos. Los resultados se resumen en la siguiente tabla:

Métrica	Valor
MSE (escala 0–1)	0.0065
Estudiantes que aprueban en realidad	264 de 300
Estudiantes predichos como aprobados	294 de 300
Exactitud (<i>accuracy</i>)	0.88
Sensibilidad (<i>recall</i>)	0.99

6. Análisis de Resultados

Aunque la exactitud y la sensibilidad obtenidas parecen altas, es importante interpretarlas con cautela. Con un umbral de 70 puntos, el 88% de los estudiantes del conjunto de prueba aprueba realmente; esto significa que un modelo que simplemente predijera “aprobado” para todos los casos, sin haber aprendido nada, alcanzaría una exactitud similar. Elevar el umbral de aprobación como a un valor cercano al promedio de las calificaciones (83) equilibra más la proporción de aprobados y reprobados, y ofrece una medida más honesta del desempeño real del modelo.

Por otro lado, aunque *study_time_hours* y *previous_grade* presentan una correlación comparativamente alta con *final_exam_score*, no son las únicas variables relacionadas con la calificación final. En el EDA inicial, *attendance_percent* mostró una correlación (0.26) y variables como *sleep_hours* e *internet_access* también presentaron correlaciones moderadas. Como estas variables no forman parte de las entradas del modelo, una parte de la información que explica la calificación final queda fuera del alcance de la red. Esto significa que, sin importar cuánto se entrene el modelo, existe un techo estructural sobre la exactitud que puede alcanzarse utilizando únicamente *previous_grade* y *study_time_hours* como variables predictoras.

7. Conclusiones

Este proyecto mostró que es posible implementar, desde cero y sin depender de un *framework*, una red neuronal funcional capaz de predecir la calificación de examen final de un estudiante con un error razonablemente bajo. Sin embargo, el análisis también evidenció dos limitaciones importantes: primero, que las métricas de clasificación (exactitud y sensibilidad) pueden resultar engañosas si no se comparan contra una línea base que considere el desbalance de clases; y segundo, que la elección de únicamente dos variables predictoras, aunque fueron las de mayor correlación disponibles, deja fuera información relevante contenida en otras variables del conjunto de datos, lo cual limita el nivel de exactitud que el modelo puede alcanzar.

Como trabajo futuro, sería valioso incorporar variables adicionales correlacionadas con la calificación final (como *previous_grade* o *sleep_hours*), agregar términos de sesgo a la red, registrar la evolución de la pérdida durante el entrenamiento, y comparar los resultados obtenidos contra una implementación equivalente utilizando un *framework*.