

Evaluación, Diagnóstico y Mejora de una Red Neuronal

Implementación y análisis de un modelo de aprendizaje supervisado

Emilio Torres Paul | A01753010

Instituto Tecnológico y de Estudios Superiores de Monterrey

1. Resumen

Este reporte evalúa, diagnostica y mejora una red neuronal feedforward que predice la calificación final de estudiantes. Primero se diagnostica el comportamiento del modelo base en términos de sesgo (bias), varianza y nivel de ajuste, concluyendo que presenta sesgo medio, varianza baja y, por tanto, sub-ajuste (*underfitting*). Después se somete el modelo a un conjunto de datos completamente nuevo, donde su desempeño cae drásticamente.

Para explicar esa caída y buscar una mejora, se construyen tres modelos que forman una secuencia experimental: el modelo base, un modelo afinado evaluado sobre los datos nuevos, y un modelo afinado evaluado sobre su propio dataset. El resultado central es que el afinado de hiperparámetros sí mejora al modelo sobre su distribución original, pero no corrige el fallo en los datos nuevos, porque ese fallo se debe a un cambio de distribución, no a una limitación del modelo.

2. Introducción

Un modelo puede rendir bien en su propia evaluación y aun así fallar ante datos nuevos. Por eso, evaluar la generalización es tan importante como medir la exactitud inicial. El marco estándar para analizar el comportamiento de un modelo es la descomposición sesgo-varianza. El sesgo mide el error sistemático por suposiciones demasiado simples (produce *underfitting*), y la varianza mide la sensibilidad a los datos concretos de entrenamiento (produce *overfitting*).

Este trabajo recorre el ciclo completo de un proyecto de aprendizaje supervisado: diagnostica el modelo base con ese marco, identifica la dirección de mejora que el diagnóstico dicta, ejecuta esa mejora mediante afinado de hiperparámetros, y verifica con datos nuevos hasta dónde la mejora es trasladable y dónde topa con un problema de naturaleza distinta.

3. Definición del Problema

Se parte de un modelo de regresión que predice `final_exam_score` (0–100) a partir de variables de comportamiento estudiantil. El problema se articula en cuatro preguntas de diagnóstico y mejora:

- ¿Qué grado de sesgo y varianza tiene el modelo base, y en qué nivel de ajuste se encuentra (*underfit* / *overfit*)?
- ¿El afinado de hiperparámetros que el diagnóstico recomienda reduce el error sobre el dataset original?
- ¿Esa mejora se traslada a un dataset nuevo e independiente?
- Si no se traslada, ¿la causa es el modelo o un cambio de distribución entre los datos?

4. Datos y Preprocesamiento

Se emplean dos conjuntos de datos de Kaggle: el original (1,000 registros), con el que se entrena y valida, y uno nuevo (960 registros válidos), reservado para la prueba de generalización. En el conjunto nuevo las columnas tienen otros nombres (*PreviousGrade*, *Study Hours*, *FinalGrade*), por lo que se renombran para coincidir con las que el modelo aprendió.

El preprocesamiento de los datos nuevos los trata como genuinamente no vistos: se eliminan las filas sin calificación real, los faltantes de las entradas se rellenan con la media del entrenamiento original, y el escalamiento reutiliza el *MinMaxScaler* ya ajustado (solo *transform*). Un hallazgo importante es que ambos datasets no comparten todas las variables de forma confiable: *sleep_hours* no existe en el nuevo, y la asistencia aparece con dos columnas, una de ellas (*Attendance (%)*). Esto condiciona qué variables pueden usarse en la prueba de generalización.

5. Metodología

El diagnóstico de sesgo y varianza se apoya en comparar errores en distintos conjuntos: el sesgo se estima por el error de entrenamiento (comparado con un modelo trivial que predice la media y con una regresión lineal), y la varianza por la brecha entre el error de entrenamiento y el de prueba sobre la misma distribución. Una brecha grande indica varianza alta (sobreajuste); una pequeña, varianza baja.

Sobre esa base se diseñan tres modelos que forman una secuencia deliberada (Tabla 1). La comparación entre ellos es lo que permite aislar la causa del error: si el afinado mejora en el mismo dataset pero no en el nuevo, la causa del fallo en datos nuevos no puede ser el modelo.

Tabla 1. Los tres modelos de la secuencia experimental.

Modelo	Configuración	Evaluado sobre	Propósito
A (base)	2 var, sigmoide, 3 neuronas	Prueba y datos nuevos	Diagnóstico inicial
B	3 var, ReLU, 5 neuronas	Datos nuevos	Probar si el afinado generaliza
C	4 var, ReLU, 5 neuronas	Mismo dataset (prueba)	Probar si el afinado mejora

6. Modelos

El modelo base (A) es una red MLPRegressor 2-3-1 con activación logística (sigmoide) y términos de sesgo (bias) en cada capa; es deliberadamente simple. Los modelos afinados (B y C) incorporan las tres técnicas que el diagnóstico de sub-ajuste recomienda: más variables de entrada (*attendance_percent*, y en C también *sleep_hours*, las siguientes en correlación con la

calificación), activación ReLU en lugar de sigmoide, y más neuronas en la capa oculta (5 en lugar de 3). Las tres son formas de aumentar la capacidad del modelo, coherentes con un problema de *underfitting* (no de *overfitting*, que requeriría lo contrario).

7. Métricas

Se usa el RMSE (error en puntos) como métrica de regresión, y para la clasificación aprobado/reprobado la exactitud (accuracy) comparada siempre contra su baseline de clase mayoritaria. La Tabla 2 concentra los resultados.

Tabla 2. Resultados de los tres modelos.

Modelo / evaluación	RMSE	Accuracy	Baseline	Veredicto
A: 2 var prueba original	7.87	0.76	0.50	Aprende (referencia)
A: 2 var datos nuevos	12.11	0.53	0.59	Bajo el baseline
B: 3 var afinado datos nuevos	12.45	0.51	0.59	Bajo el baseline
C: 4 var afinado mismo dataset	6.85	0.82	0.50	Muy por encima

8. Resultados

Diagnóstico del modelo base

El modelo base obtiene un RMSE de 7.11 en entrenamiento y 7.87 en prueba: una brecha de apenas 0.76 puntos. Mejora claramente al modelo que predice la media (~10.9), pero iguala a una regresión lineal (7.78), señal de que la capa oculta sigmoide no aporta no linealidad.

Sobre el dataset nuevo, en cambio, su RMSE se dispara a 12.11 y la exactitud cae a 0.53, por debajo de su baseline de 0.59.

Efecto del afinado

El modelo afinado sobre su propio dataset (C) reduce el RMSE de 7.87 a 6.85 y sube la exactitud (umbral equilibrado) de 0.76 a 0.82, con una brecha train–test que se mantiene baja (0.54). Pero el modelo afinado evaluado sobre los datos nuevos (B) no mejora: su exactitud queda en 0.51, igual o peor que el modelo base, y sigue por debajo del baseline. La Figura 1 hace evidente el contraste: solo el modelo evaluado sobre su mismo dataset supera su referencia.




Figura 1. Exactitud frente a la línea base en los tres experimentos. Solo el afinado sobre el mismo dataset supera la referencia.

9. Comparación

La comparación entre modelos revela la causa del problema. El contraste B vs C es el más esclarecedor: es el mismo tipo de modelo afinado, con las mismas técnicas; lo único que cambia es el dataset de evaluación. En el original alcanza 0.82; en el nuevo, 0.51. Un modelo no puede ser bueno y malo a la vez por su arquitectura. Si la diferencia depende del dataset, la causa está en los datos.




Figura 2. El afinado reduce el RMSE sobre el mismo dataset (verde), pero no sobre el dataset nuevo (rojo), donde el error permanece alto.

La causa es un cambio de distribución: los datos nuevos provienen de una población distinta, con medias desplazadas en todas las variables (*previous_grade* 69.7 vs 77.4; *study_time_hours* 3.57 vs 2.42; *final_exam_grade* 83.5 vs 80.0). El modelo aprendió una relación válida para un contexto y se le evalúa en otro; por eso falla, pese a no estar sobreajustado.

10. Discusión: Diagnóstico y Mejora en Sesgo y Varianza

Diagnóstico del modelo base: sesgo medio, varianza baja, sub-ajuste

El modelo base tiene sesgo medio: su error de entrenamiento (7.11) supera al modelo trivial, luego captura la señal dominante, pero iguala a una regresión lineal y deja un error considerable frente a la desviación estándar de la calificación (~ 10.3), lo que revela que no aprovecha más que la relación lineal. Su varianza es baja: la brecha entrenamiento–prueba es de apenas 0.76 puntos, propia de un modelo con muy pocos parámetros que no memoriza. La combinación de sesgo medio con varianza baja lo ubica del lado del sub-ajuste (*underfitting*): es demasiado simple para capturar más, pero estable.

Por qué se construyeron los tres modelos

Los tres modelos no son intentos sueltos, sino una secuencia diseñada para responder, en orden, las preguntas del problema. El modelo A establece el diagnóstico base y sirve de referencia. El modelo B (afinado, evaluado sobre datos nuevos) existe para probar si la mejora se traslada a otra distribución; su fracaso es la evidencia de que el problema de generalización no se resuelve con afinado. El modelo C (afinado, evaluado sobre el mismo dataset) existe para probar que el afinado sí mejora al modelo cuando la distribución no cambia. Juntos, B y C forman un experimento controlado: comparten el afinado y solo difieren en el dataset de evaluación, de modo que la diferencia de desempeño entre ambos aísla el efecto del cambio de distribución del efecto del modelo.

Mejora en sesgo y varianza a lo largo de la secuencia

El afinado de hiperparámetros mejora el modelo precisamente en la dimensión que el diagnóstico señalaba (el sesgo) sin sacrificar su buena varianza. Al añadir variables, cambiar a ReLU y aumentar las neuronas, el error de entrenamiento (indicador del sesgo) desciende de 7.11 a 6.44 y luego a 6.31; es decir, el modelo reduce su error sistemático y deja de comportarse como uno meramente lineal. Al mismo tiempo, la brecha entrenamiento–prueba (indicador de la varianza) se mantiene baja e incluso disminuye ligeramente, de 0.76 a 0.60 y a 0.54, lo que confirma que el aumento de capacidad no introdujo sobreajuste. La Figura 3 resume esta doble mejora: menos sesgo, varianza igualmente controlada.




Figura 3. Evolución del sesgo (RMSE de entrenamiento) y la varianza (brecha train–prueba) al afinar el modelo. El sesgo baja; la varianza permanece baja.

En términos del marco sesgo–varianza, la secuencia mueve al modelo en la dirección correcta para un caso de *underfitting*: reduce el sesgo y conserva la varianza baja, acercándolo a un mejor equilibrio. Esta es la razón por la que el afinado funciona sobre el dataset original.

El límite del afinado: el cambio de distribución

Sin embargo, ninguna de estas mejoras (que actúan sobre cómo el modelo aprende su propia distribución) puede corregir el hecho de que la distribución de evaluación es otra. Que agregar *attendance_percent* (presente en ambos datasets) no ayudara en los datos nuevos lo confirma: la variable existe, pero su escala difiere, por lo que aporta ruido fuera de su distribución original. Confundir este cambio de distribución con *underfitting* o *overfitting* llevaría a insistir en técnicas de modelado que jamás resolverían el problema.

11. Conclusiones

El recorrido completo permite concluir lo siguiente:

- Diagnóstico del modelo base: sesgo medio, varianza baja y, por tanto, *underfitting*. El modelo era estable pero demasiado simple.
- El afinado mejora sesgo y varianza en la dirección correcta: el RMSE de entrenamiento baja de 7.11 a 6.31 (menos sesgo) y la brecha train–prueba baja de 0.76 a 0.54 (varianza que se mantiene baja), elevando la exactitud de 0.76 a 0.82 sobre el dataset original.
- La mejora no se traslada a datos nuevos: la exactitud se mantiene en ~ 0.51 , por debajo del baseline, sin importar el afinado.

- La causa del fallo en datos nuevos es el cambio de distribución, no el modelo: el mismo modelo afinado rinde 0.82 en un dataset y 0.51 en otro; la diferencia la determina el dataset, no la arquitectura.

La implicación práctica es doble. Para mejorar el modelo sobre su propia distribución, el afinado de hiperparámetros es el camino correcto, y funcionó. Para que el modelo funcione sobre datos nuevos, en cambio, la solución no es seguir afinando, sino re-entrenar con datos representativos de la población objetivo (o combinar ambos conjuntos) y garantizar la consistencia e integridad de las variables entre las fuentes. En síntesis: el afinado resuelve el sesgo; solo datos representativos resuelven el cambio de distribución.